# 多模态 RAG 架构速览

个人知识库 · 离线索引 / 在线问答 / 增量更新 / 效果评测

## 1. 离线索引

PDF、Markdown、图片统一进入解析层。PDF 提取文本、表格与图片，扫描页渲染后走 OCR；Markdown 保留标题层级、代码块与表格；图片结合 OCR 与 VLM 提取文字和语义描述。清洗后的内容按标题 section 组织，使用 720 字符、120 字符重叠切块，并绑定页码、标题路径、内容类型等元数据。每个 chunk 同时进入 Chroma 向量索引和 BM25 稀疏索引。

## 2. 在线问答

问题先做查询改写与意图路由：知识问答、寒暄、知识库统计、总结、对比分别走不同路径。每个查询执行向量召回与 BM25 召回，使用 RRF 融合排名。候选片段经过 Rerank 重排后，在 3200 token 预算内拼装上下文，并为每个片段分配 [1] 形式的引用编号。生成阶段只允许模型使用资料内容，引用核查器逐句验证引用是否有原文支持。

表 1 默认检索参数

| 参数 | 默认值 | 说明 |
| --- | --- | --- |
| chunk_size | 720 | 中文语义切块粒度 |
| chunk_overlap | 120 | 跨段上下文保留 |
| dense_top_k | 14 | 向量召回数量 |
| bm25_top_k | 14 | 稀疏召回数量 |
| rerank_top_n | 6 | 进入上下文的片段数 |

# 3． 增量更新与缓存

文档用 source_key 标识来源，用 SHA-256 判断内容是否变化。内容未变时直接跳过解析与嵌入；内容变化时在同一事务中替换该文档的 chunk，提升全局 index_version，再增量写入向量并重建 BM25 快照。删除文档同样提升版本号并清理旧向量。

索引版本是所有缓存的命名空间：精确缓存 key 包含版本，语义缓存按版本过滤。缓存分为进程内 embedding 缓存、SQLite 精确缓存和基于向量相似度的语义缓存三层。只有置信度不低于 0.4 的回答才写入语义缓存，避免低质量答案被复用。

启动时检查 BM25 版本、embedding 模型签名和向量数量；任意一项不一致都会触发向量修复。修复只重新嵌入 chunk，不重新解析原始文件。

## 4． 评测

评测集使用 JSONL，标注标准答案、相关文档和证据短语。检索指标包括 Hit@5、MRR@5、nDCG@5、Context Precision 与 Recall；生成指标包括 Faithfulness、Answer Relevancy、Token F1；引用指标包括 coverage 与 accuracy；同时记录 p50/p95 延迟。每次修改切片、embedding、重排或提示词，都跑同一套评测并保留历史结果做对比。

核心结论：混合召回提升找到率，重排提升首条相关性，引用核查降低无出处断言。